

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - TIN HỌC



BÁO CÁO ĐỒ ÁN CUỐI KỲ
MÔN: PHÂN TÍCH XỬ LÝ ẢNH

Đề tài: Phân loại tổn thương da bằng EfficientNet-B0 trên bộ
dữ liệu HAM10000

GIẢNG VIÊN BỘ MÔN
ThS. Huỳnh Thanh Sơn

NHÓM SINH VIÊN THỰC HIỆN:

Nguyễn Hoàng Vũ Nguyên - 23110126

Nguyễn Thuận Phát - 23110033

Nguyễn Ngọc Đức - 23110075

Tp. Hồ Chí Minh, ngày tháng năm

Mục lục

Mục lục	1
1 TÓM TẮT & GIỚI THIỆU	1
1.1 Giới thiệu vấn đề	1
1.2 Mục tiêu	1
1.3 Lý thuyết nền sử dụng	2
2 PHƯƠNG PHÁP VÀ DỮ LIỆU	3
2.1 Dữ liệu được sử dụng	3
2.2 Kiến trúc mô hình và Pipeline	5
2.3 Quy trình Huấn luyện mô hình	7
2.3.1 Quy trình tổng quát	7
2.3.2 Huấn luyện mô hình	8
2.4 Quy trình suy luận tăng cường (TTA & MC Dropout Inference)	9
3 KẾT QUẢ VÀ THẢO LUẬN	12
3.1 So sánh Baseline và Hiệu suất huấn luyện	12
3.1.1 Hiệu suất của tập Training and Validation (Frozen Base Layers)	12
3.1.2 Hiệu suất Fine-Tuning	13
3.2 Đánh giá Tập Kiểm tra Cuối cùng	13
3.3 Phân tích Chi tiết Hiệu suất (Classification Metrics)	14
3.4 Demo hệ thống Web (Web-Based System)	17
4 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	19
4.1 Kết luận	19
4.2 Những điểm hạn chế	19
4.3 Hướng phát triển tiếp theo	20

Chương 1

TÓM TẮT & GIỚI THIỆU

1.1 Giới thiệu vấn đề

Ung thư da là một trong các bệnh ung thư phổ biến và có nguy cơ tử vong khá cao, do đó nhu cầu chẩn đoán sớm và chính xác là then chốt để tối ưu hiệu quả điều trị [1].

Tuy nhiên, quy trình chẩn đoán truyền thống thường tốn thời gian, phụ thuộc mạnh vào chuyên môn của các y bác sĩ và khó mở rộng cho sàng lọc lâm sàng quy mô lớn. Trong khi đó, các mô hình Deep Learning cho phân tích ảnh y tế dù đạt nhiều tiến bộ vẫn đối mặt các thách thức thực tiễn như: (i) mất cân bằng dữ liệu, (ii) hiệu quả tính toán/khả năng triển khai chưa cao, (iii) độ tin cậy của dự đoán, đặc biệt trong bối cảnh ứng dụng hỗ trợ quyết định lâm sàng [1].

1.2 Mục tiêu

Mục tiêu chính: Xây dựng một khung phân loại tổn thương da đa lớp nhẹ nhưng hiệu quả dựa trên **EfficientNet-B0**.

Mục tiêu kỹ thuật:

Giảm mất cân bằng dữ liệu bằng chiến lược kết hợp **tăng cường dữ liệu** cho lớp thiếu số và **giảm mẫu** cho lớp đa số.

Tăng độ chính xác và độ vững của mô hình bằng cách tích hợp: **Transfer Learning**, **Fine-Tuning** toàn mạng, **Test-Time Augmentation (TTA)**, và **MC Dropout** để hỗ trợ định lượng độ không chắc chắn.

1.3 Lý thuyết nền sử dụng

Phân loại tổn thương da: 7 lớp chẩn đoán trong HAM10000: **akiec** (Dày sừng quang hóa và ung thư biểu mô trong biểu mô), **bcc** (Ung thư biểu mô tế bào đáy), **bkl** (Tổn thương sừng lành tính), **df** (U xơ da), **mel** (U hắc tố ác tính), **nv** (Nốt ruồi sắc tố), **vasc** (Tổn thương mạch máu) [1].

CNN & Deep Learning: Mạng nơ-ron tích chập (CNN) đóng vai trò bộ trích đặc trưng chính cho ảnh tổn thương da, cho phép học biểu diễn phân cấp từ đặc trưng mức thấp (biên, texture) đến mức cao (mẫu hình tổn thương) nhằm phục vụ phân loại đa lớp.

EfficientNet-B0: được chọn vì đạt cân bằng tốt giữa hiệu năng và chi phí tính toán, phù hợp định hướng mô hình “nhẹ” nhưng vẫn đảm bảo độ chính xác cao khi triển khai thực tế [1].

Transfer Learning & Fine-Tuning: Mô hình tận dụng trọng số tiền huấn luyện để khởi tạo đặc trưng, sau đó đóng băng backbone ở giai đoạn chuyển giao học và mở khóa toàn mạng để tinh chỉnh (fine-tune) theo miền dữ liệu dermoscopy [1].

TTA & MC Dropout: Ở pha suy luận, TTA tạo nhiều biến thể ảnh và trung bình hóa xác suất dự đoán để tăng độ vững [2]; MC Dropout giữ dropout hoạt động khi suy luận và thực hiện nhiều lượt forward (ví dụ $M = 10$) để ước lượng bất định và cải thiện độ tin cậy đầu ra [3].


Chương 2

PHƯƠNG PHÁP VÀ DỮ LIỆU

2.1 Dữ liệu được sử dụng

Giới thiệu dữ liệu:

Sử dụng bộ dữ liệu HAM10000 từ Kaggle, với 10015 hình ảnh của 7 loại bệnh về ung thư da: AKIEC, BCC, BKL, DF, MEL, NV, VASC [1].



Lọc và tiền xử lí dữ liệu:

	image	MEL	NV	BCC	AKIEC	BKL	DF	VASC
0	ISIC_0024306	0.0	1.0	0.0	0.0	0.0	0.0	0.0
1	ISIC_0024307	0.0	1.0	0.0	0.0	0.0	0.0	0.0
2	ISIC_0024308	0.0	1.0	0.0	0.0	0.0	0.0	0.0
3	ISIC_0024309	0.0	1.0	0.0	0.0	0.0	0.0	0.0
4	ISIC_0024310	1.0	0.0	0.0	0.0	0.0	0.0	0.0


Hình 2.1: Dữ liệu ban đầu

Vì dữ liệu hiện tại có rất nhiều cột và chưa được chuẩn hóa, do đó ta tạo cột "dx" là label của mỗi cột và từ mã của ảnh ta trích xuất ra chính xác "image_path". Cuối cùng, tiến hành lọc, chỉ lấy 2 cột cần thiết là "image_path" và "label".

	image_path	dx	label
0	/content/HAM10000/images/ISIC_0032428.jpg	NV	1
1	/content/HAM10000/images/ISIC_0034031.jpg	BKL	4
2	/content/HAM10000/images/ISIC_0029654.jpg	NV	1
3	/content/HAM10000/images/ISIC_0025417.jpg	BCC	2
4	/content/HAM10000/images/ISIC_0030708.jpg	NV	1

Hình 2.2: Dữ liệu sau xử lý

Cân bằng dữ liệu:




Bộ dữ liệu hiện hành đang bị mất cân bằng nghiêm trọng, số lượng hình ảnh của label "NV" cao hơn rất nhiều so với các label khác, do đó phải tiến hành cân bằng dữ liệu (tương đối) bằng cách [1]:

Thực hiện Oversampling (nhân bản) để tăng số lượng mẫu của các label AKIEC, BCC, DF, VASC.

Giảm số lượng mẫu của NV xuống còn 13000.

Giữ nguyên số lượng mẫu của label BKL và MEL.

Ta được phân bố dữ liệu sau cân bằng như sau:



2.2 Kiến trúc mô hình và Pipeline

Giới thiệu mô hình: Sử dụng mô hình EfficientNet-B0 đã được xây dựng sẵn, tiếp cận mô hình với phương pháp Transfer Learning (học chuyển giao), nghĩa là từ mô hình đã có sẵn, ta tinh chỉnh sao cho phù hợp với yêu cầu bài toán đặt ra [1].

EfficientNet-B0 là mô hình mạng nơ-ron tích chập (Convolutional Neural Network – CNN) được đề xuất bởi Google (Tan & Le, 2019), với mục tiêu tối ưu hiệu năng phân loại ảnh trong khi vẫn giữ số lượng tham số và chi phí tính toán thấp [1].

EfficientNet-B0 được huấn luyện ban đầu trên tập dữ liệu ImageNet (ILSVRC 2012). ImageNet là tập dữ liệu phân loại ảnh quy mô lớn, gồm khoảng 1,2 triệu hình ảnh huấn luyện, 50.000 ảnh validation và 100.000 ảnh test, được chia thành 1000 lớp đối tượng khác nhau. Các hình ảnh trong ImageNet bao phủ nhiều nhóm như động vật, đồ vật, phương tiện, cảnh vật, giúp mô hình học được các đặc trưng thị giác tổng quát [1].

Kiến trúc mô hình: EfficientNet-B0 là mô hình mạng nơ-ron tích chập (CNN) được thiết kế với mục tiêu đạt hiệu năng cao trong khi vẫn tối ưu về số lượng tham số và chi phí tính toán. Mô hình được xây dựng dựa trên kiến trúc cơ sở được tìm kiếm tự động bằng phương pháp Neural Architecture Search (NAS).

Kiến trúc của EfficientNet-B0 bao gồm các thành phần chính sau [1]:

Input layer: Ảnh đầu vào có kích thước $224 \times 224 \times 3$.

MBConv blocks: Chuỗi các khối Mobile Inverted Bottleneck Convolution kết hợp với Depthwise Separable Convolution, giúp giảm số phép tính và số lượng tham số.

Squeeze-and-Excitation (SE) blocks: Được tích hợp trong các khối MBConv nhằm tăng khả năng học mối quan hệ giữa các kênh đặc trưng.

Activation function: Sử dụng hàm kích hoạt Swish, giúp cải thiện khả năng hội tụ của mô hình.

Global Average Pooling: Giảm chiều không gian của feature map trước khi đưa vào lớp phân loại.

Fully Connected layer: Lớp kết nối đầy đủ ở cuối mạng, được điều chỉnh theo số lượng lớp của bài toán phân loại.

Các công trình liên quan:

Phân loại ung thư da là bài toán quan trọng trong **hỗ trợ chẩn đoán lâm sàng**, song các **phương pháp truyền thống** dựa trên **đặc trưng thủ công** thường cho **hiệu quả hạn chế** và khó **tổng quát hóa**. Sự phát triển của **học sâu** với các mô hình **Convolutional Neural Network (CNN)** như **VGG**, **ResNet** và **DenseNet** đã giúp cải thiện đáng kể **độ chính xác** trên các tập dữ liệu lớn như **HAM10000**, nhưng các mô hình này thường có **kiến trúc phức tạp** và **chi phí tính toán cao** [4, 5, 6].

EfficientNet ra đời nhằm **khắc phục các hạn chế** trên thông qua **chiến lược mở rộng kiến trúc hiệu quả**. Mặc dù đã có một số nghiên cứu áp dụng **EfficientNet** cho bài toán **phân loại ung thư da**, việc khai thác **EfficientNet-B0** cùng các **kỹ thuật xử lý mất cân bằng dữ liệu** vẫn còn hạn chế. Vì vậy, đề tài này tập trung nghiên cứu **EfficientNet-B0** kết hợp **cân bằng dữ liệu** và **fine-tuning** nhằm **nâng cao hiệu quả** và **tính ứng dụng thực tế** của mô hình [1].

Phương pháp đề xuất: Vì chẩn đoán ung thư da là chủ đề nhạy cảm và cần độ chính xác cao, do đó ta áp dụng Transfer Learning với **EfficientNet-B0** kết hợp **TTA** và **MC Dropout** để tăng độ chính xác cho quá trình prediction [1]. Ngoài ra quá trình training cũng được nâng cấp hơn với việc kết hợp nhiều Augmentation trên 1 ảnh để model học được đa dạng hơn.


TTA (Test Time Augmentation): Tạo k biến thể của cùng một ảnh bằng các phép augmentation và dự đoán trên từng biến thể [2].

MC Dropout: Giữ dropout ở chế độ suy luận để thực hiện nhiều lần dự đoán với các mặt nạ dropout khác nhau, nhằm tăng độ ổn định và ước lượng bất định [3].

TTA + MC Dropout: Với mỗi ảnh, tạo k biến thể; mỗi biến thể dự đoán n_{times} lần với dropout. Kết quả cuối là trung bình của $k \times n_{\text{times}}$ dự đoán (chọn lớp có xác suất trung bình cao nhất) [2, 3].

2.3 Quy trình Huấn luyện mô hình

2.3.1 Quy trình tổng quát



Hình 2.3: Quy trình tổng quát

Đọc và chia dữ liệu: Sau khi đã cân bằng dữ liệu ta phải tiến hành đọc và chuẩn hóa để có thể đưa vào model, sau đó ta tiến hành chia dữ liệu.

Đọc và chuẩn hóa: vì dữ liệu hiện tại chỉ đang ở dạng đường dẫn tới hình ảnh, do đó ta cần trích xuất hình ảnh từ đường dẫn này và chuẩn hóa về size 224x224. Đoạn code sau xây dựng hàm tiến hành quá trình này.

```

IMG_SIZE= 224
def load_image(path, label):
    img= tf.io.read_file(path)
    img= tf.image.decode_jpeg(img,channels=3)
    img = tf.image.resize(img, [IMG_SIZE, IMG_SIZE])
    img = tf.cast(img, tf.float32)
    img= tf.keras.applications.efficientnet.preprocess_input(img)
    return img, label

```

Hình 2.4: Hàm đọc và chuẩn hóa ảnh từ đường dẫn "path"

Chia dữ liệu: ta tiến hành chia dữ liệu thành 3 tập training set, validation set, test set với tỉ lệ 70/15/15.

Tải và cài đặt Model: Quá trình tải và cài đặt gồm các bước sau.

Tải model từ tensorflow.keras.application.

Tích hợp Augmentation trực tiếp trên model: với 1 ảnh bất kì, phép augmentation sẽ tạo thành 1 ảnh khác theo quy trình sau.

```

x = layers.RandomFlip("horizontal_and_vertical")(inputs)
x = layers.RandomRotation(0.2)(x) # Xoay ngẫu nhiên 20%
x = layers.RandomZoom(0.2)(x)     # Zoom ngẫu nhiên 10%
x = layers.RandomContrast(0.1)(x) # Thay đổi độ tương phản

```

Hình 2.5: Phép Augmentation trên 1 bức ảnh (mang tính ngẫu nhiên)

Đóng băng model: Mục đích là để model giữ lại các tính chất quan trọng đã được học ví dụ xác định đâu là biên của vật thể, đâu là các chi tiết không làm ảnh hưởng đến nội dung của vật thể, đâu là nhiều,... [1].

Gắn 7 output mới cho model: EfficientNet-B0 được tải về có output là label của bộ dataset ImageNet, do đó trên tinh thần của Transfer Learning, ta gắn lại output mới để model thích ứng với chủ đề mới [1].


Cài đặt tỉ lệ MC Dropout: Đặt tỉ lệ neural bị tắt với từng ảnh được truyền vào model [3].

2.3.2 Huấn luyện mô hình

Quá trình huấn luyện mô hình diễn ra theo 2 bước:

Transfer Learning: với việc đã gán 7 output mới cho mô hình, ta phải tiến hành chạy mô hình khi đã đóng băng các lớp cơ sở, chỉ giữ lại các "head custom layer" để mô hình thích ứng với dữ liệu mới [1].

Finetunning: sau khi mô hình đã hiểu được output mới, tiến hành finetunning nghĩa là xả băng toàn bộ các lớp, để mô hình có thể học lại từ đầu [1].




Hình 2.6: Quy trình huấn luyện mô hình

Nếu fine-tune toàn bộ mô hình ngay từ đầu (không freeze base layers), các đặc trưng tổng quát từ pretrain dễ bị “ghi đè” (catastrophic forgetting), đặc biệt khi dữ liệu ít, dẫn đến overfitting. Đồng thời, cập nhật toàn bộ tham số làm huấn luyện kém ổn định và khó hội tụ nếu learning rate không đủ nhỏ. Vì vậy, hiệu năng có thể thấp hơn so với quy trình freeze backbone rồi mới fine-tune [1].

2.4 Quy trình suy luận tăng cường (TTA & MC Dropout Inference)

Sau khi mô hình đã được huấn luyện với các tham số tối ưu nhất, bước tiếp theo là dự đoán và đánh giá mô hình thông qua TTA (Test Time Augmentation) kết hợp MC Dropout [2, 3].

Quá trình suy luận, dự đoán diễn ra theo sơ đồ:



Hình 2.7: Quy trình suy luận, dự đoán

Với logic hoạt động của mô hình theo cơ chế hiện tại, quá trình dự đoán (prediction) cho một ảnh đầu vào với tham số $n_times = 10$ (tương ứng với số lần mô hình thực hiện suy luận cho cùng một ảnh) được mô tả như sau:

Test-Time Augmentation (TTA): Ở mỗi lần suy luận, ảnh đầu vào được biến đổi ngẫu nhiên (lật/xoay/scale/điều chỉnh tương phản) để tạo các phiên bản khác nhau khi dự đoán [2].

MC Dropout: Bật dropout khi suy luận; mỗi forward pass dùng một mặt nạ dropout khác nhau, phản ánh tính bất định của mô hình [3].

Lưu dự đoán: Mỗi forward pass cho ra phân phối xác suất theo lớp; lưu lại toàn bộ các dự đoán tương ứng từng biến thể ảnh và mặt nạ dropout.

Lặp $n_times = 10$: Lặp quy trình trên 10 lần cho cùng một ảnh để thu tập dự đoán phục vụ tổng hợp (trung bình/đa số).

```
for i in range(n_times):          # MC Dropout
    predict(original_image)       # augmentation được sinh bên trong model
```

Hình 2.8: Pseudo-code

Kết quả dự đoán cuối cùng được xác định bằng cách lấy trung bình (mean) các phân phối xác suất thu được từ 10 lần suy luận. Nhãn dự đoán

cuối cùng là lớp có xác suất trung bình cao nhất, đồng thời quá trình này cũng giúp cải thiện độ ổn định và độ tin cậy của kết quả dự đoán thông qua việc kết hợp cả Test-Time Augmentation và MC Dropout [2, 3].

Chương 3

KẾT QUẢ VÀ THẢO LUẬN

3.1 So sánh Baseline và Hiệu suất huấn luyện

3.1.1 Hiệu suất của tập Training and Validation (Frozen Base Layers)

Trong giai đoạn huấn luyện ban đầu, nhóm áp dụng *transfer learning* với **backbone EfficientNet-B0** được **đóng băng** và chỉ huấn luyện phần phân loại trong **20 epochs** [1]. Kết quả cho thấy mô hình cải thiện nhanh ở giai đoạn đầu: **training accuracy** tăng từ **31.87%** (Epoch 1) lên **66.81%** (Epoch 20), đồng thời **validation accuracy** tăng từ **58.03%** lên **68.41%**. Điểm **validation accuracy** cao nhất trong giai đoạn này đạt **70.19%** tại **Epoch 14**. Song song đó, cả training/validation loss đều giảm tương đối ổn định, cho thấy mô hình học hiệu quả khi giữ nguyên đặc trưng nền từ ImageNet và thích nghi dần với miền ảnh dermoscopy.

Bảng 3.1: Tóm tắt hiệu suất huấn luyện (EfficientNet-B0, frozen base, 20 epochs).

Epoch	Train Loss	Train Acc (%)	Val Loss	Val Acc (%)
1	2.0334	31.87	1.2793	58.03
10	0.9555	64.46	0.9109	67.35
14*	0.9226	65.99	0.8946	70.19
20	0.9076	66.81	0.8987	68.41

*Epoch 14 là mốc đạt validation accuracy cao nhất trong giai đoạn frozen base.

Bảng 3.2: So sánh độ chính xác baseline của các backbone (trước fine-tuning).

Train:Val:Test	EfficientNet-B0	ResNet50	DenseNet121	MobileNetV2	InceptionV3
70:15:15	78.6%	81.81%	72.05%	75.69%	73.03%

Nhận xét về so sánh baseline: Kết quả trong Bảng 3.2 cho thấy **ResNet50** đạt độ chính xác cao nhất ở giai đoạn baseline (**81.81%**), trong khi **EfficientNet-B0** đạt **78.6%**. Tuy nhiên, các kết quả này chỉ phản ánh hiệu suất khi backbone được đóng băng và chủ yếu phục vụ mục đích benchmark ban đầu. Do đó, việc lựa chọn mô hình không chỉ dựa trên accuracy ở giai đoạn baseline mà còn xét đến tiềm năng cải thiện sau fine-tuning cũng như khả năng triển khai thực tế [1].

3.1.2 Hiệu suất Fine-Tuning

Sau khi mô hình đã hội tụ sơ bộ, nhóm tiến hành **fine-tuning** bằng cách mở khóa backbone và tiếp tục huấn luyện từ **Epoch 21 đến Epoch 35** [1]. Ở thời điểm bắt đầu fine-tuning, các chỉ số có thể dao động do toàn bộ tham số được cập nhật trở lại. Tuy nhiên, sau quá trình tinh chỉnh, hiệu suất tăng rõ rệt, cho thấy fine-tuning giúp backbone học được đặc trưng phù hợp hơn với dữ liệu HAM10000.

Bảng 3.3: Tóm tắt hiệu suất fine-tuning (EfficientNet-B0, unfreeze backbone, Epoch 21–35).

Epoch	Train Loss	Train Acc (%)	Val Loss	Val Acc (%)
21	1.9031	41.15	1.0382	65.75
25	0.5957	77.69	0.7439	74.09
30	0.3391	87.55	0.7075	77.55
35	0.2610	90.16	0.5511	82.08

3.2 Đánh giá Tập Kiểm tra Cuối cùng

Mô hình EfficientNet-B0 được đánh giá trên tập kiểm tra gồm **1127** ảnh. Ở chế độ suy luận có áp dụng *test-time augmentation (TTA)*, mô hình đạt **accuracy = 0.8749** (tương đương **87.49%**) [2, 1]. Báo cáo phân loại chi tiết được trình bày trong Bảng 3.4.

Bảng 3.4: Báo cáo phân loại trên tập test (TTA inference) của mô hình EfficientNet-B0 với 7 lớp HAM10000.

Class	Precision	Recall	F1-Score	Support
mel	0.86	0.57	0.69	167
nv	0.74	0.92	0.82	195
bcc	0.89	0.94	0.92	150
akiec	0.97	0.97	0.97	150
bkl	0.78	0.75	0.76	165
df	0.99	1.00	1.00	150
vasc	0.99	1.00	0.99	150
Accuracy			0.87	1127
Macro Avg.	0.89	0.88	0.88	1127
Weighted Avg.	0.88	0.87	0.87	1127

Bảng 3.5: So sánh hiệu năng các mô hình sau khi tinh chỉnh (Fine-tuning).

Model	Accuracy (No TTA)	Accuracy (with TTA)
DenseNet121	78.00%	81.21%
InceptionV3	81.00%	82.33%
MobileNetV2	82.27%	84.50%
ResNet50	87.22%	85.00%
EfficientNet-B0	86.69%	87.49%

Tổng kết lựa chọn mô hình: Bảng 3.5 cho thấy **ResNet50** đạt độ chính xác cao nhất khi không sử dụng TTA. Tuy nhiên, khi áp dụng TTA, hiệu suất của **ResNet50** suy giảm, trong khi **EfficientNet-B0** cải thiện và đạt độ chính xác cao nhất. Kết quả này cho thấy **EfficientNet-B0** có khả năng tổng quát hóa và độ ổn định tốt hơn dưới các biến đổi dữ liệu, đồng thời phù hợp hơn cho triển khai thực tế nhờ kiến trúc gọn nhẹ và chi phí tính toán thấp.

3.3 Phân tích Chi tiết Hiệu suất (Classification Metrics)

Báo cáo phân loại (Classification Report)

Bảng 3.4 cho thấy mô hình EfficientNet-B0 đạt hiệu suất cao trên tập kiểm tra (1127 ảnh) trong thiết lập suy luận có áp dụng TTA. Các lớp **df**


($F1 = 1.00$), **vasc** ($F1 = 0.99$) và **akiec** ($F1 = 0.97$) được nhận diện rất ổn định, trong khi các lớp **mel** ($F1 = 0.69$) và **bkl** ($F1 = 0.76$) có độ khó cao hơn do đặc trưng hình ảnh chồng lấn. Tổng thể, mô hình đạt **Accuracy = 0.87**, với **Macro F1 = 0.88** và **Weighted F1 = 0.87**, cho thấy hiệu năng cân bằng giữa các lớp.

Ma trận nhầm lẫn (Confusion Matrix)


Hình 3.1 minh họa ma trận nhầm lẫn tương ứng với cấu hình suy luận *TTA + MC Dropout* [2, 3]. Các giá trị trên đường chéo chính nhìn chung cao, đặc biệt với **nv** (153/153) và **vasc** (155/155). Các nhầm lẫn đáng chú ý tập trung ở các cặp lớp có biểu hiện hình thái tương đồng: (i) **akiec** bị nhầm sang **bcc** (17 mẫu) và **mel** (12 mẫu); (ii) **bcc** bị nhầm sang **akiec** (22 mẫu) và **mel** (14 mẫu); (iii) **mel** bị nhầm sang **akiec** (20 mẫu), **bcc** (10 mẫu) và **df** (12 mẫu). Những nhầm lẫn này phù hợp với việc F1-score của **akiec** và **mel** thấp hơn các lớp còn lại, và gợi ý cần tinh chỉnh thêm chiến lược huấn luyện/suy luận cho nhóm lớp khó.

ROC và AUC

Hình 3.2 minh họa các đường cong ROC–AUC cho bài toán phân loại đa lớp theo chiến lược *one-vs-rest* trong thiết lập suy luận có áp dụng TTA. Kết quả cho thấy mô hình EfficientNet-B0 đạt AUC cao trên hầu hết các lớp, bao gồm **DF** và **VASC** ($AUC = 1.00$), **BCC** và **AKIEC** ($AUC = 0.99$), **NV** ($AUC = 0.98$), **BKL** ($AUC = 0.96$) và **MEL** ($AUC = 0.93$). Đồng thời, các chỉ số *micro-average* và *macro-average* AUC đều đạt **0.98**, phản ánh khả năng phân tách lớp mạnh mẽ và hiệu năng cân bằng giữa các lớp, nhất quán với các kết quả Accuracy và F1-score đã trình bày trước đó.



Hình 3.1: Ma trận nhầm lẫn của mô hình EfficientNet-B0 ở chế độ suy luận $TTA + MC Dropout$.



Hình 3.2: Phân tích ROC-AUC cho 7 lớp theo chiến lược one-vs-rest.

3.4 Demo hệ thống Web (Web-Based System)

Nhằm đánh giá khả năng ứng dụng thực tế của mô hình đề xuất, nhóm thực hiện đã triển khai kiến trúc EfficientNet-B0 [1] vào một hệ thống phát hiện ung thư da trên nền tảng web. Hệ thống này đóng vai trò là giao diện tương tác thực nghiệm, cho phép tự động hóa quy trình phân loại tổn thương và cung cấp các chỉ số hỗ trợ ra quyết định lâm sàng.

Về mặt kỹ thuật, ứng dụng được phát triển trên ngôn ngữ Python, sử dụng framework **Streamlit** [7] để xây dựng giao diện người dùng và thư viện **TensorFlow** [8] để vận hành quy trình suy luận (*inference*). Trọng số của mô hình sau quá trình huấn luyện và tinh chỉnh (*fine-tuning*) được lưu trữ dưới định dạng **.h5** và tích hợp trực tiếp vào hệ thống xử lý.

Quy trình sử dụng hệ thống: Giao diện được thiết kế tối giản để người dùng thao tác nhanh chóng qua 3 bước:

Bước 1 - Tải ảnh: Người dùng tải lên ảnh tổn thương da (định dạng JPG/PNG) từ thiết bị.

Bước 2 - Phân tích: Nhấn nút "Tiến hành chẩn đoán" để gửi dữ liệu đến mô hình AI.

Bước 3 - Nhận kết quả: Hệ thống hiển thị ngay lập tức tên bệnh dự đoán và biểu đồ phân tích.

Cơ chế xử lý và suy luận:

Tiền xử lý: Ảnh đầu vào được tự động chuẩn hóa về kích thước 224×224 pixels bằng thuật toán Lanczos resampling để tương thích với mô hình.

Suy luận: Mô hình trích xuất đặc trưng và tính toán xác suất; nhãn dự đoán là lớp có độ tin cậy (*confidence score*) cao nhất [3].

Trực quan hóa: Kết quả được biểu diễn qua biểu đồ thanh (sử dụng thư viện Altair [9]), giúp minh bạch hóa mức độ chắc chắn của AI.

Hệ thống Hỗ trợ Chẩn đoán Ung thư Da

Lưu ý quan trọng: Hệ thống sử dụng mô hình AI (EfficientNet-B0) để hỗ trợ sàng lọc bước đầu. Kết quả không có giá trị thay thế chẩn đoán y khoa. Vui lòng luôn tham vấn bác sĩ chuyên khoa Da liễu.

1. Tải ảnh lên

Drag and drop file here
Limit 200MB per file • JPG, PNG, JPEG

Browse files

2. Phân tích & Kết quả

TIẾN HÀNH CHẨN ĐOÁN

Vui lòng tải ảnh ở cột bên trái.

Hình 3.3: Giao diện nhập liệu của hệ thống, cho phép người dùng tải ảnh tổn thương da để phân tích.

Hệ thống Hỗ trợ Chẩn đoán Ung thư Da


Lưu ý quan trọng: Hệ thống sử dụng mô hình AI (EfficientNet-B0) để hỗ trợ sàng lọc bước đầu. Kết quả không có giá trị thay thế chẩn đoán y khoa. Vui lòng luôn tham vấn bác sĩ chuyên khoa Da liễu.

1. Tải ảnh lên

Drag and drop file here
Limit 200MB per file • JPG, PNG, JPEG

Browse files

ISC_0034405.jpg 204.8KB



Ảnh lâm sàng đầu vào

2. Phân tích & Kết quả


TIẾN HÀNH CHẨN ĐOÁN

Ung thư Tế bào đáy (BCC)

Đánh giá: ● Nguy cơ cao (Malignant)

Độ tin cậy của AI: 93.43%

Chỉ số phân phối xác suất:



Hình 3.4: Kết quả chẩn đoán từ hệ thống, bao gồm nhãn phân loại, mức độ cảnh báo và biểu đồ phân phối xác suất tin cậy (Confidence Score).

Phân tích kết quả thực nghiệm:

- **Cách đọc kết quả:** Hệ thống hiển thị tên bệnh kèm nhãn màu cảnh báo (Đỏ: nguy cơ cao, Xanh: lành tính). Biểu đồ xác suất giúp người dùng nhận biết được sự "lưỡng lự" của mô hình giữa các lớp bệnh để có hướng xử lý phù hợp.
- **Hạn chế triển khai:** Độ chính xác dự đoán phụ thuộc nhiều vào chất lượng ảnh đầu vào (độ nét, ánh sáng, góc chụp) [5, 1]. Ngoài ra, tốc độ phản hồi thực tế có thể dao động tùy thuộc vào đường truyền mạng và cấu hình máy chủ.

Chương 4

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

4.1 Kết luận

Nghiên cứu đã xây dựng thành công khung mô hình EfficientNet-B0 cho bài toán phân loại đa lớp tổn thương da [1].

Quy trình tiền xử lý và cân bằng lớp giúp giảm tác động của mất cân bằng dữ liệu, hỗ trợ mô hình học ổn định hơn [1].

Hệ thống tích hợp Transfer Learning, Fine-Tuning, TTA và MC Dropout; trong thực nghiệm hiện tại của nhóm, mô hình đạt độ chính xác 87.49% trên tập kiểm tra (1127 mẫu) [1, 2, 3].

Với kiến trúc gọn nhẹ và khả năng mở rộng, EfficientNet-B0 phù hợp hướng triển khai trong bối cảnh tài nguyên tính toán hạn chế [1].

4.2 Những điểm hạn chế

Mất cân bằng lớp còn ảnh hưởng: Dù đã xử lý, một số lớp khó (đặc biệt **akiec**, **mel**) vẫn có F1 thấp hơn và dễ nhầm lẫn với **bcc/df**.

Phụ thuộc cách chia dữ liệu: Kết quả có thể dao động theo seed/split; chưa có đánh giá ổn định bằng k-fold cross-validation.

TTA/MC Dropout chưa tối ưu: Augmentation ở suy luận có thể quá mạnh hoặc cấu hình MC Dropout chưa chuẩn (BN/Dropout), mặc dù độ chính xác đạt 87.49%, nhưng vẫn còn khoảng cách so với các nghiên cứu SOTA (State-of-the-art) trên cùng bộ dữ liệu (thường >90%)[2, 3].

Chưa kiểm chứng tổng quát hóa ngoài miền: Chưa test trên tập độc lập khác nguồn (ISIC/clinic khác), nên khả năng generalization còn chưa chắc chắn.

Giải thích mô hình còn hạn chế: Chưa có Grad-CAM/attention map để minh họa vùng quyết định, khó thuyết phục khi ứng dụng lâm sàng.

Ràng buộc triển khai thực tế: Chưa đo latency/throughput trên thiết bị yếu (mobile/edge), cũng chưa đánh giá độ bền với nhiễu, blur, ánh sáng kém.

4.3 Hướng phát triển tiếp theo

Khảo sát và tích hợp các phương pháp siêu phân giải nhẹ (lightweight super-resolution) nhằm cải thiện chất lượng ảnh đầu vào, đặc biệt với ảnh có độ phân giải thấp/thiếu chi tiết [1].

Cải thiện định lượng độ không chắc chắn (uncertainty quantification) để tăng độ tin cậy khi hỗ trợ quyết định, nâng cao khả năng ứng dụng lâm sàng [3, 1].

Tài liệu tham khảo

- [1] S. Das and R. K. Addya. “Skin Cancer Detection and Classification Through Medical Image Analysis Using EfficientNet”. In: *Journal of Non-Destructive Testing (NDT)* 3.4 (2025), p. 23. DOI: 10 . 3390 / ndt3040023.
- [2] Divya Shanmugam et al. “When and Why Test-Time Augmentation Works”. In: *arXiv preprint arXiv:2011.11156* (2020). URL: <https://arxiv.org/abs/2011.11156>.
- [3] Yarin Gal and Zoubin Ghahramani. “Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning”. In: *Proceedings of the 33rd International Conference on Machine Learning (ICML)*. 2016. URL: <https://proceedings.mlr.press/v48/gal16.html>.
- [4] A. Naeem et al. “Malignant Melanoma Classification Using Deep Learning: Datasets, Performance Measurements, Challenges and Opportunities”. In: *IEEE Access* 8 (2020), pp. 110575–110597.
- [5] S. Nazari and R. Garcia. “Automatic Skin Cancer Detection Using Clinical Images: A Comprehensive Review”. In: *Life* 13 (2023), p. 2123.
- [6] C. Kavitha et al. “Skin Cancer Detection and Classification Using Deep Learning Techniques”. In: *Procedia Comput. Sci.* 235 (2024), pp. 2793–2802.
- [7] Streamlit Inc. *Streamlit Documentation*. <https://docs.streamlit.io>. Accessed: 2025-01-15. 2023.
- [8] Martín Abadi et al. “TensorFlow: A system for large-scale machine learning”. In: *12th USENIX symposium on operating systems design and implementation (OSDI 16)*. 2016, pp. 265–283.
- [9] Jacob VanderPlas et al. “Altair: Interactive statistical visualizations for Python”. In: *Journal of open source software* 3.32 (2018), p. 1057.