

Phân loại tổn thương da bằng EfficientNet-B0 trên bộ dữ liệu HAM10000

GVMH: ThS. Huỳnh Thanh Sơn

Nhóm Sinh Viên: N.H.V Nguyễn, N.T. Phát, N.N. Đức

Khoa Toán - Tin học
Trường Đại học Khoa học tự nhiên, ĐHQG-HCM

25/01/2026

Nội dung trình bày

- 1 Mở đầu
 - Giới thiệu vấn đề
 - Mục tiêu đề tài
- 2 Dữ liệu & Quy trình tiền xử lý
 - Dữ liệu HAM10000
 - Chiến lược cân bằng dữ liệu
 - Tiền xử lý dữ liệu
- 3 Phương pháp & Kiến trúc mô hình
 - Kiến trúc EfficientNet-B0
 - Quy trình huấn luyện mô hình
 - Kỹ thuật suy luận nâng cao
- 4 Kết quả & Phân tích
 - Hiệu suất huấn luyện
 - Đánh giá trên tập Kiểm tra (Test set)
 - Phân tích sai số và Độ tin cậy
 - Demo Hệ thống
- 5 Kết luận & Hướng phát triển

Nội dung trình bày

- 1 Mở đầu
 - Giới thiệu vấn đề
 - Mục tiêu đề tài
- 2 Dữ liệu & Quy trình tiền xử lý
 - Dữ liệu HAM10000
 - Chiến lược cân bằng dữ liệu
 - Tiền xử lý dữ liệu
- 3 Phương pháp & Kiến trúc mô hình
 - Kiến trúc EfficientNet-B0
 - Quy trình huấn luyện mô hình
 - Kỹ thuật suy luận nâng cao
- 4 Kết quả & Phân tích
 - Hiệu suất huấn luyện
 - Đánh giá trên tập Kiểm tra (Test set)
 - Phân tích sai số và Độ tin cậy
 - Demo Hệ thống
- 5 Kết luận & Hướng phát triển

Tính cấp thiết

- Ung thư da là bệnh phổ biến, nguy cơ tử vong cao nếu không phát hiện sớm. Nhu cầu chẩn đoán sớm là **then chốt** để tối ưu điều trị [1].
- Quy trình truyền thống tốn thời gian, phụ thuộc mạnh vào **chuyên môn** bác sĩ và khó mở rộng sàng lọc quy mô lớn [2, 3].

Thách thức thực tiễn của Deep Learning

- Mất cân bằng dữ liệu [1].
- Hiệu quả tính toán và Khả năng triển khai [1].
- Độ tin cậy của dự đoán [4, 5].

Mục tiêu chính: Xây dựng khung phân loại tổn thương da đa lớp **nhẹ** nhưng **hiệu quả** dựa trên **EfficientNet-B0** [1].

Mục tiêu kỹ thuật:


- **Giảm mất cân bằng dữ liệu:** Kết hợp chiến lược **tăng cường dữ liệu** (cho lớp thiểu số) và **giảm mẫu** (cho lớp đa số) [1].
- **Tăng độ chính xác và độ ổn định:** Tích hợp Transfer Learning, Fine-Tuning toàn mạng, **Test-Time Augmentation (TTA)** và **MC Dropout** để hỗ trợ định lượng độ không chắc chắn [5, 4].

Nội dung trình bày

- 1 Mở đầu
 - Giới thiệu vấn đề
 - Mục tiêu đề tài
- 2 Dữ liệu & Quy trình tiền xử lý
 - Dữ liệu HAM10000
 - Chiến lược cân bằng dữ liệu
 - Tiền xử lý dữ liệu
- 3 Phương pháp & Kiến trúc mô hình
 - Kiến trúc EfficientNet-B0
 - Quy trình huấn luyện mô hình
 - Kỹ thuật suy luận nâng cao
- 4 Kết quả & Phân tích
 - Hiệu suất huấn luyện
 - Đánh giá trên tập Kiểm tra (Test set)
 - Phân tích sai số và Độ tin cậy
 - Demo Hệ thống
- 5 Kết luận & Hướng phát triển

Tổng quan bộ dữ liệu:


- **Nguồn:** Kaggle (HAM10000), bao gồm **10.015 ảnh dermoscopic** thô.
- **Phân lớp:** 7 loại tổn thương da (AKIEC, BCC, BKL, DF, MEL, NV, VASC).



Hình 1: Minh họa hình ảnh của 7 loại tổn thương da.

Chiến lược cân bằng dữ liệu

Vấn đề cốt lõi: Mất cân bằng dữ liệu nghiêm trọng, trong đó lớp NV (nốt ruồi lành tính) chiếm đa số áp đảo.




Hình 2: Phân bố dữ liệu ban đầu - lớp NV chiếm áp đảo

Chiến lược cân bằng dữ liệu

Phương pháp tiếp cận:

- **Oversampling (Tăng mẫu):** Tăng số lượng mẫu các label AKIEC, BCC, DF, VASC [1].
- **Undersampling (Giảm mẫu):** Giảm số lượng mẫu NV từ **6,705** xuống **1,300** mẫu [1].
- **Kết quả:** Tổng bộ dữ liệu sau cân bằng: **7,512 ảnh**.



Hình 3: Phân bố dữ liệu sau cân bằng - các lớp đã được cân đối

Tiền xử lý dữ liệu

	image	MEL	NV	BCC	AKIEC	BKL	DF	VASC		image_path	dx
0	ISIC_0024306	0.0	1.0	0.0	0.0	0.0	0.0	0.0	/content/HAM10000/images/ISIC_0024306.jpg	NV	
1	ISIC_0024307	0.0	1.0	0.0	0.0	0.0	0.0	0.0	/content/HAM10000/images/ISIC_0024307.jpg	NV	
2	ISIC_0024308	0.0	1.0	0.0	0.0	0.0	0.0	0.0	/content/HAM10000/images/ISIC_0024308.jpg	NV	
3	ISIC_0024309	0.0	1.0	0.0	0.0	0.0	0.0	0.0	/content/HAM10000/images/ISIC_0024309.jpg	NV	
4	ISIC_0024310	1.0	0.0	0.0	0.0	0.0	0.0	0.0	/content/HAM10000/images/ISIC_0024310.jpg	MEL	

Hình 4: Mẫu dữ liệu thô ban đầu (Dataframe).

Tiền xử lý (Preprocessing):

- Trích xuất ảnh và chuẩn hóa kích thước về **224 × 224** pixels (chuẩn EfficientNet).
- Chia tập dữ liệu: Train (**70%**) - Validation (**15%**) - Test (**15%**).

Nội dung trình bày

- 1 Mở đầu
 - Giới thiệu vấn đề
 - Mục tiêu đề tài
- 2 Dữ liệu & Quy trình tiền xử lý
 - Dữ liệu HAM10000
 - Chiến lược cân bằng dữ liệu
 - Tiền xử lý dữ liệu
- 3 Phương pháp & Kiến trúc mô hình
 - Kiến trúc EfficientNet-B0
 - Quy trình huấn luyện mô hình
 - Kỹ thuật suy luận nâng cao
- 4 Kết quả & Phân tích
 - Hiệu suất huấn luyện
 - Đánh giá trên tập Kiểm tra (Test set)
 - Phân tích sai số và Độ tin cậy
 - Demo Hệ thống
- 5 Kết luận & Hướng phát triển

Lý do lựa chọn EfficientNet-B0:


Cân bằng tốt giữa **độ chính xác** và **chi phí tính toán** (FLOPs), phù hợp để triển khai thực tế [1].

Đặc điểm kỹ thuật nổi bật:

- **Khối MBConv:** Sử dụng *Mobile Inverted Bottleneck* giúp giảm thiểu tham số nhưng vẫn giữ được đặc trưng quan trọng [1].
- **Cơ chế SE (Squeeze-and-Excitation):** Tự động học và trọng số hóa các kênh đặc trưng quan trọng của tổn thương da [1].
- **Hàm kích hoạt Swish:** Giúp cải thiện khả năng hội tụ và độ chính xác so với ReLU truyền thống [1].

Quy trình huấn luyện mô hình

Quy trình huấn luyện tổng quát



Hình 5: Quy trình từ xử lý dữ liệu đến đánh giá mô hình.

Quy trình huấn luyện mô hình

Cài đặt mô hình:

Thiết lập MC Dropout:

- **Thao tác:** Cài đặt tỷ lệ tắt ngẫu nhiên các neural trong Dropout Layer.
- **Cơ chế:** Giữ Dropout hoạt động trong quá trình suy luận (inference) bằng cách đặt `training=True` để tạo nhiều dự đoán xác suất, nhằm định lượng độ không chắc chắn của mô hình [4].

Cài đặt Augmentation (trong huấn luyện):

- **Thao tác:** Ảnh đầu vào được đưa qua các lớp biến đổi ngẫu nhiên: Xoay (0.2), Zoom (0.2), Lật (ngang/dọc), Tương phản (0.1).
- **Mục đích:** Tăng tính đa dạng cho dữ liệu ngay trong quá trình huấn luyện trên GPU, giúp giảm thiểu Overfitting [5].

Quy trình huấn luyện mô hình

Mô hình được huấn luyện qua 2 giai đoạn:


Transfer Learning - Epoch 1-20

- **Thao tác:** Đóng băng (Freeze) backbone, chỉ huấn luyện Head phân loại.
- **Mục đích:** Giữ đặc trưng ImageNet, giúp hội tụ nhanh [1].

Fine-tuning - Epoch 21-35

- **Thao tác:** Mở băng (Unfreeze) toàn bộ mạng.
- **Mục đích:** Học đặc trưng chuyên biệt để tinh chỉnh sâu các đặc trưng ảnh y tế [1].

Quy trình huấn luyện mô hình



Hình 6: Quy trình huấn luyện mô hình

Kỹ thuật suy luận nâng cao

Mục tiêu: Tăng độ ổn định và định lượng độ bất định thông qua **TTA** và **MC Dropout** [5, 4].

Test-Time Augmentation (TTA)


Thay vì dự đoán 1 lần, mô hình dự đoán nhiều lần trên nhiều biến thể (xoay, lật) của cùng 1 ảnh, sau đó lấy kết quả trung bình → **Giảm thiểu sai sót ngẫu nhiên** [5].

MC Dropout (Định lượng độ bất định)

Duy trì Dropout ngay cả khi suy luận (Inference) để tạo ra phân phối xác suất [4].

- Nếu các lần dự đoán **dao động lớn** → **Độ bất định cao** (Mô hình thiếu tự tin).
- Hỗ trợ bác sĩ biết khi nào nên tin vào AI.

Kỹ thuật suy luận nâng cao



Hình 7: Quy trình suy luận dự đoán.

Nội dung trình bày

- 1 Mở đầu
 - Giới thiệu vấn đề
 - Mục tiêu đề tài
- 2 Dữ liệu & Quy trình tiền xử lý
 - Dữ liệu HAM10000
 - Chiến lược cân bằng dữ liệu
 - Tiền xử lý dữ liệu
- 3 Phương pháp & Kiến trúc mô hình
 - Kiến trúc EfficientNet-B0
 - Quy trình huấn luyện mô hình
 - Kỹ thuật suy luận nâng cao
- 4 Kết quả & Phân tích
 - Hiệu suất huấn luyện
 - Đánh giá trên tập Kiểm tra (Test set)
 - Phân tích sai số và Độ tin cậy
 - Demo Hệ thống
- 5 Kết luận & Hướng phát triển

Hiệu suất huấn luyện

Bảng 1: Giai đoạn Frozen Base (Epoch 1–20)

Epoch	Train Loss	Train Acc (%)	Val Loss	Val Acc (%)
1	2.0334	31.87	1.2793	58.03
10	0.9555	64.46	0.9109	67.35
14*	0.9226	65.99	0.8946	70.19
20	0.9076	66.81	0.8987	68.41

Bảng 2: Giai đoạn Fine-tuning (Epoch 21–35)

Epoch	Train Loss	Train Acc (%)	Val Loss	Val Acc (%)
21	1.9031	41.15	1.0382	65.75
25	0.5957	77.69	0.7439	74.09
30	0.3391	87.55	0.7075	77.55
35*	0.2610	90.16	0.5511	82.08

- Fine-tuning giúp cải thiện **Val Accuracy** từ **khoảng 70%** lên **khoảng 82%**.

Đánh giá trên tập Kiểm tra (Test set)

So sánh hiệu năng giữa các mô hình

Bảng 3: So sánh độ chính xác (Accuracy) trên tập Test.

Model	Acc (No TTA)	Acc (with TTA)
DenseNet121	78.00%	81.21%
InceptionV3	81.00%	82.33%
MobileNetV2	82.27%	84.50%
ResNet50	87.22%	85.00% (↓)
EfficientNet-B0	86.69%	87.49% (↑)

Nhận xét:

- **TTA** cải thiện rõ rệt tính ổn định với EfficientNet-B0 so với ResNet50.
- EfficientNet-B0 kết hợp TTA đạt độ chính xác cao nhất (**87.49%**), đồng thời cho hiệu năng ổn định hơn so với các mô hình khác.


Đánh giá trên tập Kiểm tra (Test set)

Chi tiết hiệu năng từng lớp (EfficientNet-B0 + TTA)

Bảng 4: Báo cáo phân loại chi tiết cho 7 lớp bệnh.

Class	Precision	Recall	F1-Score	Support
mel	0.86	0.57	0.69	167
nv	0.74	0.92	0.82	195
bcc	0.89	0.94	0.92	150
akiec	0.97	0.97	0.97	150
bkl	0.78	0.75	0.76	165
df	0.99	1.00	1.00	150
vasc	0.99	1.00	0.99	150
Accuracy			0.87	1127
Macro Avg.	0.89	0.88	0.88	1127
Weighted Avg.	0.88	0.87	0.87	1127

Phân tích sai số: Ma trận nhầm lẫn




Hình 8: Ma trận nhầm lẫn của mô hình EfficientNet-B0 ở chế độ suy luận TTA + MC Dropout.

Tổng quan: Các giá trị tập trung chủ yếu trên đường chéo chính.

Các cặp nhầm lẫn đáng chú ý:

- **AKIEC** ↔ **BCC**: Nhầm lẫn do cùng là tổn thương biểu mô.
- **MEL** ↔ **NV**: Nhầm lẫn do sự tương đồng lớn về hình thái sắc tố.

Độ tin cậy mô hình: Biểu đồ ROC-AUC



Hình 9: Phân tích ROC-AUC cho 7 lớp theo chiến lược one-vs-rest.

Khả năng phân tách lớp: AUC trung bình đạt **khoảng 0.98**.

Chi tiết từng lớp:

- **Xuất sắc:** DF, VASC ($AUC \approx 1.0$).
- **Tốt:** BCC, AKIEC ($AUC \approx 0.99$).
- **Cần cải thiện:** MEL ($AUC \approx 0.93$) thấp nhất do khó phân biệt với nốt ruồi (NV).

Ứng dụng hỗ trợ quyết định lâm sàng (Clinical Decision Support):

- **Công nghệ:** Python, Streamlit, TensorFlow.
- **Đầu ra:** Dự đoán tên bệnh + Mức độ cảnh báo rủi ro + Điểm độ tin cậy (Confidence Score).

Hệ thống Hỗ trợ Chẩn đoán Ung thư Da

 Lưu ý quan trọng: Hệ thống sử dụng mô hình AI (EfficientNet-B0) để hỗ trợ sàng lọc bước đầu. Kết quả không có giá trị thay thế chẩn đoán y khoa. Vui lòng luôn tham vấn bác sĩ chuyên khoa Da liễu.

1. Tải ảnh lên

 Drag and drop file here
Limit 200MB per file • JPG, PNG, JPEG

[Browse files](#)

2. Phân tích & Kết quả

 TIẾN HÀNH CHẨN ĐOÁN

 Vui lòng tải ảnh ở cột bên trái.

Hình 10: Giao diện nhập liệu và tải ảnh của hệ thống.

Hệ thống Hỗ trợ Chẩn đoán Ung thư Da


Lưu ý quan trọng: Hệ thống sử dụng mô hình AI (EfficientNet B0) để hỗ trợ sàng lọc bước đầu. Kết quả không có giá trị thay thế chẩn đoán y khoa. Vui lòng tuân thủ vận bác sĩ chuyên khoa Da liễu.

1. Tải ảnh lên

Drag and drop file here
Upload 200MB per file • JPG, PNG, GIF

Upload file

ISC_0024405.jpg 254.8KB



Ảnh lâm sàng đầu vào

2. Phân tích & Kết quả

Tiền hành chẩn đoán

Ung thư Tế bào đáy (BCC)

Đánh giá: ● Nguy cơ cao (Malignant)

Độ tin cậy của AI: 93.41%

Chi tiết phân phối xác suất:



Hình 11: Kết quả chẩn đoán và Trực quan hóa độ tin cậy.

Nội dung trình bày

- 1 Mở đầu
 - Giới thiệu vấn đề
 - Mục tiêu đề tài
- 2 Dữ liệu & Quy trình tiền xử lý
 - Dữ liệu HAM10000
 - Chiến lược cân bằng dữ liệu
 - Tiền xử lý dữ liệu
- 3 Phương pháp & Kiến trúc mô hình
 - Kiến trúc EfficientNet-B0
 - Quy trình huấn luyện mô hình
 - Kỹ thuật suy luận nâng cao
- 4 Kết quả & Phân tích
 - Hiệu suất huấn luyện
 - Đánh giá trên tập Kiểm tra (Test set)
 - Phân tích sai số và Độ tin cậy
 - Demo Hệ thống
- 5 Kết luận & Hướng phát triển

Tổng kết:

- **Mô hình hiệu quả:** Xây dựng thành công hệ thống dựa trên **EfficientNet-B0**, tích hợp Transfer Learning và Fine-tuning toàn mạng [1].
- **Độ chính xác ấn tượng:** Đạt **87.49%** trên tập kiểm tra (1127 mẫu) nhờ kỹ thuật suy luận nâng cao (TTA & MC Dropout) [5, 4].
- **Tối ưu triển khai:** Kiến trúc mô hình gọn nhẹ, phù hợp ứng dụng trong bối cảnh tài nguyên tính toán hạn chế [1].

Hạn chế & Hướng phát triển

Những điểm hạn chế tồn tại:

- **Mất cân bằng lớp:** Vẫn còn nhầm lẫn ở các lớp khó (như **MEL** và **NV**) do đặc trưng hình ảnh chồng lấn [2, 3].
- **Tính tổng quát hóa:** Chưa kiểm chứng trên nguồn dữ liệu độc lập khác (cross-domain generalization) [3].
- **Khả năng giải thích:** Thiếu cơ chế minh bạch hóa vùng quyết định (như Grad-CAM) để thuyết phục bác sĩ [3].

Hướng phát triển tiếp theo:

- **Siêu phân giải (Super-resolution):** Tích hợp mô hình nhẹ để khôi phục chi tiết cho ảnh đầu vào chất lượng thấp/mờ [6].
- **Explainable AI (XAI):** Phát triển Attention Map/Grad-CAM để khoanh vùng tổn thương, nâng cao độ tin cậy lâm sàng [3].
- **Cải tiến kiến trúc (Advanced Architectures):** Thử nghiệm các dòng mô hình lai (Hybrid CNN-Transformer) hoặc Ensemble Learning để nâng cao độ chính xác nhận diện các lớp khó (như MEL/NV).[3].

- [1] S. Das and R. K. Addya, "Skin cancer detection and classification through medical image analysis using efficientnet," *Journal of Non-Destructive Testing (NDT)*, vol. 3, no. 4, p. 23, 2025.
- [2] A. Naeem, M. S. Farooq, A. Khelifi, and A. Abid, "Malignant melanoma classification using deep learning: Datasets, performance measurements, challenges and opportunities," *IEEE Access*, vol. 8, pp. 110575–110597, 2020.
- [3] S. Nazari and R. Garcia, "Automatic skin cancer detection using clinical images: A comprehensive review," *Life*, vol. 13, p. 2123, 2023.
- [4] Y. Gal and Z. Ghahramani, "Dropout as a bayesian approximation: Representing model uncertainty in deep learning," in *Proceedings of the 33rd International Conference on Machine Learning (ICML)*, 2016.
- [5] D. Shanmugam, D. Blalock, G. Balakrishnan, and J. Guttag, "When and why test-time augmentation works," *arXiv preprint arXiv:2011.11156*, 2020.

- [6] C. Kavitha, S. Priyanka, M. P. Kumar, and V. Kusuma, "Skin cancer detection and classification using deep learning techniques," *Procedia Comput. Sci.*, vol. 235, pp. 2793–2802, 2024.